

Waleria Phillip
Paweł Piechota

STEAM GAME SUCCESS PREDICTION

Predykcja sukcesu gier komputerowych na platformie Steam przy użyciu uczenia maszynowego



PREDYKCJA SUKCESU GIER NA STEAM

● Kontekst Badania i Cele Projektu

Platforma Steam to największy cyfrowy sklep z grami komputerowymi, oferujący ponad 100 000 tytułów. Dynamiczny wzrost rynku sprawia, że przewidywanie sukcesu nowych gier staje się kluczowym wyzwaniem dla deweloperów i wydawców.

Celem projektu jest opracowanie modelu uczenia maszynowego, który na podstawie cech gry: gatunku, ceny, ocen i metadanych, pozwoli prognozować jej popularność i sukces komercyjny na platformie Steam.



ETAPY PROJEKTU ML

● **Zbieranie Danych**

Pobranie danych o grach ze Steam Store Games Dataset z serwisu Kaggle. Zebrano informacje o gatunkach, cenach, liczbie ocen, osiągnięć oraz czasu gry.

● **Wybór Modeli**


Porównanie algorytmów: DummyClassifier, Logistic Regression, oraz Random Forest Classifier. Dobór hiperparametrów metodą Grid Search CV.

● **Preprocessing**

Obsługa brakujących wartości, kodowanie zmiennych kategorycznych oraz normalizacja cech numerycznych na potrzeby modeli ML.

● **Ewaluacja Modeli**

Do ocena skuteczności przy użyciu metryk: accuracy, precision, F1-score



ANALIZA ZBIORU DANYCH

27K+
Gier Steam

Zbiór danych zawiera ponad 27 075 gier ze platformy Steam. Rozkład ocen jest nierównomierny – dominują tytuły z oceną pozytywną (60–80%), co wymaga technik balansowania klas w modelowaniu.

● Kluczowe Cechy Predykcyjne

Najważniejsze zmienne: liczba recenzji, cena, gatunek, data wydania, liczba graczy oraz wsparcie dla wielu platform. Cechy te wykazują najwyższą korelację z sukcesem komercyjnym gry.

PROBLEMY Z CECHAMI WEJŚCIOWYMI

● Błędne cechy

W pierwszej wersji projektu wykorzystano zestaw cech, które okazały się zbyt ogólne lub zawierały informacje silnie powiązane z klasą docelową. W rezultacie modele osiągały bardzo wysoką skuteczność (około 99%), jednak wyniki te nie odzwierciedlały rzeczywistej zdolności modelu do uogólniania wiedzy na nowe dane.

● Zbieranie Danych


Tak wysoka precyzja sugerowała możliwość występowania przeuczenia (overfitting) lub wycieku informacji (data leakage), przez co konieczna była ponowna analiza danych wejściowych.

WYNIKI PODCZAS PIERWSZEGO ZESTAWU CECH

● Porównanie Algorytmów Klasyfikacji

Random Forest osiągnął najwyższą dokładność 99.9%, niewiele przewyższając Regresję Logistyczną (99.3%) i Dummy (49,7%). GridSearch osiągnął 0.997 potwierdzając wysoką skuteczność modelu.

Szczegóły



OPTYMALIZACJA ZBIORU DANYCH

● **Zbieranie Danych**

Przeprowadzono ponowną analizę zbioru danych oraz wykorzystanych cech. Utworzono nowe cechy, które mogły dostarczać modelowi mniej bezpośrednich informacji o przewidywanej klasie.

● **Zbieranie Danych**


Celem zmian było zwiększenie realizmu eksperymentu oraz sprawdzenie rzeczywistej zdolności modeli do klasyfikacji danych na podstawie istotnych zależności, a nie zapamiętanych wzorców.

WYNIKI MODELI ML

● Porównanie Algorytmów Klasyfikacji

Random Forest osiągnął najwyższą dokładność 77,0%, niewiele przewyższając Regresję Logistyczną (76,6%) i Dummy (49,0%). GridSearch osiągnął 78,8% potwierdzając wysoką skuteczność modelu.

Szczegóły





WNIOSKI

● Kluczowe odkrycia i kierunki rozwoju

Najsilniejszymi predyktorami sukcesu gier na Steam okazały się: liczba pozytywnych i negatywnych ocen, oraz cechy danej gry. Modele Random Forest i Logistic Regression osiągnęły najwyższą skuteczność klasyfikacji, osiągając ok 80% dokładności.

Ograniczenia badania obejmują niską ilość danych w porównaniu do pełnej ilości możliwych danych. W przyszłości warto uwzględnić analizę sentymentu recenzji oraz dane z mediów społecznościowych, co może znacząco poprawić jakość predykcji.



DZIĘKUJĘ

ZA UWAGĘ!