

Autorzy:

Waleria Philipp

Paweł Piechota

Predykcja sukcesu gier komputerowych na platformie Steam przy użyciu uczenia maszynowego

Spis treści

Spis treści	1
1. Cel i Definicja Problemu.....	2
2. Dane i Wstępna Analiza Eksploracyjna (EDA)	2
2.1. Opis i czyszczenie zbioru danych	2
2.2. Analiza statystyczna i wizualna	3
3. Ewolucja Cech (Feature Engineering) i Problem Data Leakage.....	5
Etap I: Wstępna inżynieria cech i identyfikacja błędu metodologicznego (Data Leakage)	5
Etap II: Budowa czystych cech rynkowych.....	6
4. Modelowanie i Optymalizacja	8
5. Ewaluacja i Analiza Wyników	8
5.1. Szczegółowa analiza metryk dla optymalnego modelu (GridSearch RF).....	8
5.2. Interpretacja istotności cech	9
6. Podsumowanie i Wnioski	10
6.1. Wnioski metodologiczne (Czego nauczyły nas błędy?)	10
6.2. Wnioski biznesowe (Co faktycznie decyduje o sukcesie?)	11

1. Cel i Definicja Problemu

Celem niniejszego projektu było zbudowanie modelu klasyfikacji binarnej dedykowanego do prognozowania sukcesu komercyjnego i wizerunkowego gier na platformie Steam. Sukces gry (y) został zdefiniowany jako osiągnięcie liczby pozytywnych recenzji powyżej mediany wyznaczonej dla całego zbioru danych:

$$y = \text{positive_ratings} > \text{median}(\text{positive_ratings})$$

Platforma Steam boryka się z problemem ogromnej asymetrii, obok globalnych hitów codziennie pojawiają się dziesiątki niszowych produkcji, które nie są w stanie przebić się do świadomości graczy. Z perspektywy niezależnych twórców, zrozumienie niejawnych zależności między cechami gry (cena, czas rozgrywki, konstrukcja mechaniczna gry) a ostatecznym odbiorem przez społeczność ma kluczowe znaczenie biznesowe. Wielowymiarowy i nieliniowy charakter tych zależności uzasadnia porzucenie prostych analiz statystycznych na rzecz algorytmów uczenia maszynowego.

2. Dane i Wstępna Analiza Eksploracyjna (EDA)

2.1. Opis i czyszczenie zbioru danych

Wykorzystaliśmy rzeczywisty zbiór danych zawierający informacje o 27 075 grach na platformie Steam, opisanych przez 18 cech wyjściowych.


Nazwa kolumny	Opis
appid	Unikalny identyfikator gry na platformie Steam
name	Nazwa gry
release_date	Data wydania gry
english	Informacja, czy gra posiada język angielski (1 – tak, 0 – nie)
developer	Producent gry
publisher	Wydawca gry
platforms	Platformy, na których dostępna jest gra
required_age	Minimalny wymagany wiek gracza
categories	Kategorie przypisane do gry
genres	Gatunki gry
steamspy_tags	Tagi opisujące grę
achievements	Liczba osiągnięć dostępnych w grze
positive_ratings	Liczba pozytywnych ocen użytkowników
negative_ratings	Liczba negatywnych ocen użytkowników
average_playtime	Średni czas gry (w minutach)
median_playtime	Mediana czasu gry (w minutach)
owners	Szacowana liczba właścicieli gry
price	Cena gry

Tabela 1. Struktura i opis atrybutów wyjściowych zbioru danych platformy Steam


- Obsługa braków: Identyfikacja brakujących wartości za pomocą `df.isnull().sum()` wykazała minimalne braki w kolumnach kategoriowych: `developer` (1 rekord) oraz `publisher` (14 rekordów). Braki te zostały bezpiecznie uzupełnione ciągiem znaków "Unknown".
- Weryfikacja duplikatów: Funkcja `df.duplicated().sum()` zwróciła wartość 0.

2.2. Analiza statystyczna i wizualna

Struktura rynku: Wyodrębnienie najpopularniejszych gatunków ujawniło silną dominację gier niezależnych (Indie), akcji (Action) oraz przygodowych (Adventure).



Wykres 1. Top 10 Most Common Genres – Wykres słupkowy rozkładu liczebności najpopularniejszych gatunków.



Wykres 2. Top 10 Developers on Steam – Zestawienie najbardziej produktywnych studiów deweloperskich.

Analiza struktury cenowej wykazała silną asymetrię rozkładu. Średnia cena produktu wynosi około 6.08\$, podczas gdy 75% bazy zamyka się w kwocie 7.19\$. W zbiorze danych obecne są

jednak pojedyncze pozycje o skrajnie wysokich cenach, sięgających aż do 421.99\$, co tworzy bardzo długi prawostronny ogon rozkładu.



Wykres 3. Distribution of Game Prices – Histogram rozkładu cen z wyraźnym długim ogonem wartości odstających.

Aby zapobiec destabilizacji modeli wrażliwych na rozpiętość skali, zastosowaliśmy technikę clippingu (obcięcia) cen do poziomu 155\$. Wszystkie wartości powyżej tego progu zostały sprowadzone do wartości maksymalnej, co pozwoliło zachować ciągłość danych przy jednoczesnym ograniczeniu wpływu pojedynczych anomalii rynkowych.


3. Ewolucja Cech (Feature Engineering) i Problem Data Leakage

Proces budowy zestawu zmiennych prognostycznych przebiegał dwuetapowo z powodu wykrycia błędu metodologicznego w pierwszej fazie prac.

Etap I: Wstępna inżynieria cech i identyfikacja błędu metodologicznego (Data Leakage)

W pierwotnej wersji stworzyliśmy cechy silnie agregujące zachowania użytkowników: `total_ratings`, `rating_ratio` (stosunek ocen pozytywnych do wszystkich) oraz `log_ratings`.

Wstępne testy modeli przyniosły nienaturalnie wysokie wyniki dokładności (Regresja Logistyczna: 99.31%, Las Losowy: 99.87%). Analiza macierzy korelacji wyjaśniła to zjawisko:



Wykres 4. Correlation Heatmap - Steam Games Dataset (Old Features) – Mapa korelacji ujawniająca bezpośrednie powiązanie zmiennych wejściowych ze zmienną docelową.


Wniosek: Wystąpiło zjawisko Data Leakage (wycieku danych). Zmienna `rating_ratio` determinowała stan zmiennej docelowej, udostępniając modelowi informacje z przyszłości (wiedzę o ocenach, które gra dopiero zdobędzie).

Etap II: Budowa czystych cech rynkowych

W celu naprawy błędu, usunięto wszystkie cechy oparte na recenzjach. Zaprojektowano nowy zestaw zmiennych:

- `game_age`: Wiek gry obliczony na podstawie roku wyciągniętego z daty premiery (`release_date`) względem roku referencyjnego 2025.
- `has_achievements`: Flaga obecności systemu osiągnięć w grze.
- `is_adult`: Flaga określająca ograniczenie wiekowe 18+.

Zmienne ciągłe (`price`, `average_playtime`, `median_playtime`, `game_age`) poddano standaryzacji przy użyciu klasy `StandardScaler`.



Wykres 5: Correlation Heatmap - NEW Features (Steam Dataset) – Nowa macierz korelacji, potwierdzająca brak nieuprawnionego wycieku informacji.

Nowa heatmapa pokazuje silną korelację między `average_playtime` a `median_playtime`. Oznacza to silną współliniowość, obie zmienne dublują tę samą informację. W przyszłości warto byłoby zrezygnować z jednej z nich (np. zostawić tylko `median_playtime`, która jest odporniejsza na graczy skrajnie zawyżających średnią). Usunięcie tego dubla uprości model, skróci czas obliczeń i zmniejszy ryzyko przeuczenia, nie pogarszając jakości predykcji.

Aby zachować pełną przejrzystość metodologiczną, poniżej zestawiono kompletne składy macierzy cech X dla obu podejść. Pokazuje to, które zmienne były wspólne, a które uległy zmianie.

- Cechy wspólne dla obu modeli (Baza porównawcza):
 - `price` (cena gry)
 - `is_free` (flaga darmowości)
 - `average_playtime` (średni czas gry)
 - `median_playtime` (medianowy czas gry)
- Cechy unikalne dla Wersji I (Usunięte z powodu Data Leakage):
 - `rating_ratio` (stosunek ocen pozytywnych do sumy ocen)
 - `log_ratings` (zlogarytmowana całkowita liczba ocen)
- Cechy unikalne dla Wersji II (Wprowadzone czyste cechy rynkowe):
 - `game_age` (wiek rynkowy gry)
 - `has_achievements` (flaga obecności osiągnięć)

- `is_adult` (flaga ograniczenia wiekowego 18+)

Dzięki temu, że rdzeń modelu (`price`, `is_free`, `average_playtime`, `median_playtime`) pozostał niezmienny, uzyskaliśmy idealne warunki do obserwacji, jak usunięcie "toksycznych" zmiennych wpłynęło na te podstawowe cechy.

W pierwszej wersji cechy wspólne (jak cena czy czas gry) były całkowicie bezużyteczne dla modeli, ponieważ algorytmy opierały się wyłącznie na `rating_ratio`. Dopiero w drugiej wersji, po odcięciu wycieku danych, ta sama baza (`price`, `is_free` oraz czasy rozgrywki) mogła w pełni zaprezentować swoją rzeczywistą siłę predykcyjną i stała się głównym filarem prognozowania sukcesu gry.

4. Modelowanie i Optymalizacja

Do weryfikacji hipotez badawczych wykorzystano podział danych na zbiór treningowy i testowy (proporcja 80/20) oraz dwa główne algorytmy:

1. Regresja Logistyczna (Logistic Regression): Jako liniowy model referencyjny.
2. Las Losowy (Random Forest): Jako złożony model ansamblowy (drzewiasty).

Optymalizację hiperparametrów dla struktury Lasu Losowego przeprowadzono za pomocą procedury `GridSearchCV` z 3-krotną walidacją krzyżową, dostrajając liczbę estymatorów (`n_estimators`), maksymalną głębokość (`max_depth`) oraz minimalną liczbę próbek wymaganych do podziału liścia (`min_samples_split`, `min_samples_leaf`).

5. Ewaluacja i Analiza Wyników

Po całkowitym wyeliminowaniu problemu wycieku danych oraz poprawnym przeprowadzeniu ewaluacji końcowej na ustandaryzowanym zbiorze testowym (`X_test_new_scaled`), modele osiągnęły stabilne i realistyczne wyniki.

	Model	Old features	New features
0	Logistic Regression	0.993167	0.766390
1	Random Forest	0.998707	0.770822
2	GridSearch RF	0.997045	0.780609

Tabela 2. Zbiorcze zestawienie dokładności dla obu podejść

5.1. Szczegółowa analiza metryk dla optymalnego modelu (GridSearch RF)


Ostateczna weryfikacja na poprawnie przeskalowanych danych testowych pozwoliła uzyskać pełen profil metryk dla optymalnego klasyfikatora:

- Accuracy: 0.7806 – Model poprawnie klasyfikuje około 78% tytułów.

- Precision: 0.8261 – Wysoka precyzja wskazuje, że jeśli model prognozuje sukces gry, to myli się rzadko.
- F1-score: 0.7663 – Średnia harmoniczna potwierdza zrównoważoną charakterystykę predykcyjną modelu.

5.2. Interpretacja istotności cech

Analiza zachowania modeli pozwoliła określić, które atrybuty mają kluczowe znaczenie dla predykcji sukcesu gry na platformie Steam.



Wykres 6: Feature Importance - Random Forest (New Features) – Wykres ważności cech w modelu Lasu Losowego.

Zarówno wskaźniki ważności Lasu Losowego, jak i dodatnie współczynniki regresji logistycznej wskazują na następujące zależności:

- Wskaźniki zaangażowania (average_playtime, median_playtime): Stanowią najważniejszy komponent predykcyjny. Zdolność gry do zatrzymania gracza na długie godziny silnie implikuje ostateczny sukces (wysokie, dodatnie współczynniki w modelu liniowym).
- Wiek gry (game_age): Cecha o najwyższej ważności w strukturze drzewiastej (0.2384) i silnym dodatnim wpływie w regresji. Wynika to ze specyfiki dystrybucji starszych gier w ekosystemie Steam, pozycje historyczne obecne w bazie to w dużej mierze tytuły o ugruntowanej pozycji.
- Cena (price) i darmowość (is_free): Obie zmienne stymulują szansę na sukces, co sugeruje korzyści płynące ze strategii polaryzacyjnych (oferowanie produktu jako Free-to-Play w celu budowania skali lub pozycjonowanie go jako produkt Premium).

CECHY ZWIĘKSZAJĄCE SZANSĘ SUKCESU:

	Feature	Coefficient
1	average_playtime	5.260909
2	median_playtime	3.952019
4	game_age	1.020934
0	price	0.651844
3	is_free	0.571109
5	has_achievements	0.493602
6	is_adult	0.101795

Tabela 3: Cechy wpływające na szansę sukcesu gry w modelu Regresji Logistycznej.

Bardzo interesującym wnioskiem z tej analizy jest fakt, że żadna z uwzględnionych w ostatecznym modelu cech nie uzyskała ujemnego współczynnika. Każda z zaprojektowanych przez nas zmiennych działa na plus, czyli w mniejszym lub większym stopniu zwiększa szansę gry na osiągnięcie sukcesu (znalezienie się powyżej mediany pozytywnych ocen).

6. Podsumowanie i Wnioski

Realizacja projektu była dla nas doskonałą, choć momentami bolesną lekcją praktycznego uczenia maszynowego. Pozwoliła nam ona na wyciągnięcie kluczowych wniosków na dwóch płaszczyznach:

6.1. Wnioski metodologiczne (Czego nauczyły nas błędy?)

- Pokora wobec "zbyt pięknych" wyników: Pierwsza faza projektu i legendarne już metryki na poziomie 99.87% skuteczności dobitnie pokazały, jak łatwo wpaść w pułapkę data leakage. Zrozumieliśmy, że jeśli model radzi sobie na danych rynkowych niemal bezbłędnie, to nie oznacza to, że napisaliśmy algorytm stulecia, ale że przez przypadek daliśmy mu ściągawkę z odpowiedziami.
- Zróżnicowanie struktur danych i skrajne rozpiętości: Praca ze zbiorem danych Steam uświadomiła nam, jak wielkim wyzwaniem jest sytuacja, w której minima i maksima poszczególnych cech leżą na zupełnie innych biegunach. Podczas gdy flaga `is_free` przyjmuje proste wartości 0 lub 1, to czas rozgrywki (`playtime`) czy liczby ocen liczone są w tysiącach, a nawet milionach. Co więcej, każda cecha wymagała zupełnie innej strategii, aby model mógł optymalnie wykorzystać jej potencjał informacyjny:
 - Dla ceny idealny okazał się *clipping* (obcięcie), który zneutralizował wpływ pojedynczych, nienaturalnie drogich produktów.

- Dla czasu gry i wieku kluczowa była standaryzacja, która sprowadziła te ogromne wartości liczbowe do wspólnej skali, dzięki czemu algorytmy liniowe nie "zwariowały".
- Dla cech kategorycznych (takich jak osiągnięcia czy ograniczenia wiekowe) najlepszym rozwiązaniem była ich binaryzacja (zamiana na flagi 0/1).

Zrozumieliśmy, że w czyszczeniu danych nie ma jednego uniwersalnego szablonu, każdą cechę trzeba traktować indywidualnie i dopasowywać transformację do jej specyfiki rynkowej. Nie da się wrzucić wszystkiego do jednego worka bez wcześniejszego przemyślenia.

6.2. Wnioski biznesowe (Co faktycznie decyduje o sukcesie?)

- Czas gry to fundament: Najważniejsza konkluzja z analizy modeli (zwłaszcza Regresji Logistycznej) to fakt, że zaangażowanie graczy (`average_playtime` i `median_playtime`) to absolutnie najważniejsze czynniki korelujące z sukcesem gry. Jeśli mechanika potrafi utrzymać użytkownika przed ekranem, oceny automatycznie idą w górę.
- Fenomen wyłącznie pozytywnych cech: Bardzo zaskakującym, ale optymistycznym odkryciem był fakt, że żadna z czystych cech rynkowych nie działała na szkodę gry. Zarówno wyższa cena (często utożsamiana z lepszą jakością i segmentem premium), wiek gry, jak i posiadanie osiągnięć, wszystko to mniejszym lub większym stopniu podnosiło szansę na sukces w oczach społeczności Steam.