

	Politechnika Opolska		W I
	Projekt Narzędzia sztucznej inteligencji		
Kierunek:	Informatyka	Rok i semestr studiów nr:	III rok VI semestr
Rok akademicki:	2025/2026	Grupa laboratoryjna:	2
Prowadzący:	mgr inż. Michał Wierzbicki		
Skład zespołu	Paweł Piechota	Nr indeksu	105518
	Waleria Philipp		105471

Predykcja sukcesu gier komputerowych na platformie Steam przy
użyciu uczenia maszynowego

Spis treści

Spis treści	1
1. Opis projektu.....	2
2. Sformułowanie problemu badawczego	2
3. Uzasadnienie wyboru tematu.....	2
4. Czy zastosowanie uczenia maszynowego jest uzasadnione?.....	2
5. Cechy	3
6. Analiza wstępna danych (EDA).....	4
7. Wizualizacja danych.....	4
I. Rozkład cen gier.....	4
II. Najpopularniejsze gatunki gier	5
III. Najwięksi deweloperzy gier	5
8. Wnioski z EDA.....	5
9. Uzupełnienie braków.....	6
Sprawdzenie duplikatów	6
10. Feature engineering (tworzenie nowych cech)	6
I) Weryfikacja utworzonych cech.....	7
II) Transformacje danych	7
III) Uzasadnienie decyzji.....	7
IV) Wpływ feature engineering na model (porównanie przed i po)	7
11. Model i eksperymenty	8
Dobór metryk	9
Analiza wyników	9
Heatmapa	9
12. Wnioski z eksperymentów	9
13. Podsumowanie.....	10
Interpretacja wyników	10
Refleksja (co działało / co nie).....	10
Osiągnięcie celu	10

1. Opis projektu

Czy dane o grze zdradzają jej przyszły sukces? Celem projektu jest analiza czynników wpływających na sukces gier komputerowych na platformie Steam oraz sprawdzenie czy metody uczenia maszynowego są w stanie przewidywać powodzenie gry na podstawie dostępnych danych. W ramach projektu zostanie przeprowadzona analiza wybranych cech gier, takich jak cena, gatunek, liczba osiągnięć, data wydania czy oceny użytkowników. Następnie dane zostaną odpowiednio przygotowane i przetworzone, a na ich podstawie zbudowane i porównane modele predykcyjne uczenia maszynowego. Efektem pracy będzie określenie, które czynniki mają największy wpływ na sukces gry oraz ocena skuteczności zastosowanych modeli w przewidywaniu jej powodzenia.

2. Sformułowanie problemu badawczego

Problem badawczy projektu dotyczy możliwości przewidywania sukcesu gier komputerowych na platformie Steam na podstawie ich cech oraz identyfikacji najważniejszych zmiennych wpływających na wynik. Kluczowe pytanie brzmi, czy istnieją mierzalne zależności pozwalające oszacować powodzenie gry przy użyciu metod uczenia maszynowego.

3. Uzasadnienie wyboru tematu

Każdy, kto gra w gry komputerowe, choć raz zastanawiał się, dlaczego jedne tytuły nagle stają się ogromnym sukcesem, a inne mimo dobrych zapowiedzi szybko znikają z rynku. Z zewnątrz często wydaje się to dość losowe, choć jednocześnie można mieć wrażenie, że pewne cechy gier powtarzają się wśród popularnych produkcji. Ten temat został wybrany z ciekawości, czy takie obserwacje można „przetłumaczyć” na język danych i sprawdzić przy pomocy uczenia maszynowego. Innymi słowy czy komputer, analizując informacje o grze, byłby w stanie zauważyć to, co dla gracza często jest tylko intuicją. Projekt łączy więc zainteresowanie grami z chęcią sprawdzenia, jak sztuczna inteligencja radzi sobie z przewidywaniem zjawisk, które na pierwszy rzut oka wydają się nie do końca przewidywalne.

4. Czy zastosowanie uczenia maszynowego jest uzasadnione?

W tym projekcie uczenie maszynowe ma szczególne zastosowanie, ponieważ trudno jednoznacznie określić, co decyduje o sukcesie gry. Wpływa na niego wiele różnych czynników, które razem tworzą złożony obraz i nie zawsze dają się łatwo przeanalizować. Zastosowanie modeli uczenia maszynowego pozwala przeanalizować te zależności w sposób wielowymiarowy i wykryć powiązania, które mogą nie być widoczne przy klasycznej analizie. Dzięki temu możliwe jest zarówno przewidywanie sukcesu gry, jak i lepsze zrozumienie, które cechy mają na niego największy wpływ.

5. Cechy

W projekcie wykorzystano zbiór danych Steam Store Games Dataset pochodzący z serwisu Kaggle. Dataset zawiera informacje o ponad 27 tysiącach gier dostępnych na platformie Steam, takie jak gatunki, cena, liczba ocen, osiągnięcia oraz czas gry. Zbiór został wybrany ze względu na bezpośredni związek z celem projektu, którym jest przewidywanie sukcesu gry komputerowej.

Cecha	Opis
appid	Unikalny identyfikator gry na platformie Steam
name	Nazwa gry
release_date	Data wydania gry
english	Informacja, czy gra posiada język angielski (1 – tak, 0 – nie)
developer	Producent gry
publisher	Wydawca gry
platforms	Platformy, na których dostępna jest gra
required_age	Minimalny wymagany wiek gracza
categories	Kategorie przypisane do gry
genres	Gatunki gry
steamspy_tags	Tagi opisujące grę
achievements	Liczba osiągnięć dostępnych w grze
positive_ratings	Liczba pozytywnych ocen użytkowników
negative_ratings	Liczba negatywnych ocen użytkowników
average_playtime	Średni czas gry (w minutach)
median_playtime	Mediana czasu gry (w minutach)
owners	Szacowana liczba właścicieli gry
price	Cena gry

Zbiór danych zawiera 27 075 rekordów (gier) oraz 18 cech opisujących właściwości gier dostępnych na platformie Steam.

Zbiór danych zawiera 18 cech opisujących gry komputerowe na platformie Steam. Dane obejmują m.in. informacje o cenie, gatunku gry, ocenach użytkowników, czasie gry oraz wydawcy. Na tym etapie analizy nie zdefiniowano jeszcze zmiennej docelowej (klasy), która zostanie utworzona w dalszej części projektu na potrzeby modelowania.

6. Analiza wstępna danych (EDA)

W ramach analizy wstępnej przeprowadzono eksplorację zbioru danych Steam Store Games Dataset z 2019 roku zawierającego 27 075 rekordów oraz 18 cech opisujących gry dostępne na platformie Steam.

Na początku wykonano podstawową analizę struktury danych przy użyciu funkcji “head()”, “info()” oraz “shape”, co pozwoliło określić liczbę obserwacji, typy danych oraz ogólną strukturę zbioru.

Następnie przeprowadzono analizę statystyczną za pomocą “describe()”, która umożliwiła zapoznanie się z rozkładem wartości liczbowych, takich jak cena gier, liczba ocen użytkowników oraz czas rozgrywki.


Sprawdzono również występowanie braków danych przy użyciu funkcji “isnull().sum()”. Wykazano, że zbiór danych jest w dużej mierze kompletny, a brakujące wartości występują jedynie w kolumnach dotyczących producenta (developer) oraz wydawcy (publisher).

7. Wizualizacja danych

W ramach eksploracyjnej analizy danych wykonano trzy podstawowe wizualizacje, których celem było lepsze zrozumienie struktury oraz charakterystyki zbioru danych.

I. Rozkład cen gier

Pierwszy wykres przedstawia rozkład cen gier dostępnych na platformie Steam. Analiza wykazała, że większość gier ma niską cenę, a znaczna część tytułów jest darmowa lub kosztuje niewiele. Oznacza to, że rynek Steam jest silnie zdominowany przez gry o niskiej cenie, co może wpływać na konkurencyjność produktów premium.




Zdj. 1 – Tablica rozkładu ilości gier do cen

II. Najpopularniejsze gatunki gier

Drugi wykres przedstawia 10 najczęściej występujących gatunków gier. Wyniki wskazują, że dominują gatunki takie jak Action, Indie oraz Adventure. Sugeruje to, że na


platformie Steam szczególnie popularne są gry akcji oraz gry niezależne, które stanowią istotną część całego zbioru danych.



Zdj. 2 – Tabela najpopularniejszych gier od ilości.

III. Najwięksi deweloperzy gier

Trzeci wykres przedstawia 10 deweloperów, którzy opublikowali największą liczbę gier w analizowanym zbiorze. Wyniki pokazują, że rynek jest zdominowany przez stosunkowo niewielką liczbę producentów, którzy odpowiadają za dużą część dostępnych tytułów. Jednocześnie widoczna jest duża liczba mniejszych twórców, co potwierdza zróżnicowanie rynku gier komputerowych.



Zdj. 3 – Tabela najpopularniejszych deweloperów.

8. Wnioski z EDA

Przeprowadzona analiza wizualna pozwoliła lepiej zrozumieć strukturę danych Steam. Zaobserwowano, że:

- większość gier ma niską cenę lub jest darmowa,
- dominują gry z gatunków Action, Indie i Adventure,
- rynek gier jest częściowo skoncentrowany wokół kilku dużych deweloperów, ale jednocześnie bardzo zróżnicowany.

Wnioski te będą podstawą do dalszych etapów projektu, w tym przygotowania danych oraz budowy modelu uczenia maszynowego. W celu poprawy czytelności wizualizacji oraz ograniczenia wpływu wartości odstających, ceny gier zostały przycięte do maksymalnej wartości 60 dolarów, zgodnie z obserwacjami z analizy eksploracyjnej.

9. Uzupełnienie braków

W danych występowały niewielkie braki w kolumnach “developer” oraz “publisher”. Zostały one uzupełnione wartością "Unknown".

Sprawdzenie duplikatów

W trakcie analizy danych sprawdzono występowanie duplikatów w zbiorze. Nie wykryto żadnych zduplikowanych rekordów, co oznacza, że każdy wpis w datasetcie reprezentuje unikalną grę. Dzięki temu nie było konieczności przeprowadzania procesu usuwania duplikatów, a dane mogą zostać wykorzystane bez dodatkowych modyfikacji w tym zakresie.

10. Feature engineering (tworzenie nowych cech)

W ramach przygotowania danych zastosowano feature engineering, czyli proces tworzenia nowych zmiennych na podstawie istniejących danych w celu poprawy jakości analizy oraz modeli uczenia maszynowego.

Utworzono następujące cechy:

- `total_ratings` - suma pozytywnych i negatywnych ocen, określająca ogólną popularność gry.
- `rating_ratio` - stosunek pozytywnych ocen do wszystkich ocen, pozwalający lepiej ocenić jakość gry niezależnie od jej popularności.
- `log_ratings` - logarytm liczby wszystkich ocen, zastosowany w celu zmniejszenia wpływu wartości odstających oraz poprawy rozkładu danych.
- `is_free` - zmienna binarna określająca, czy gra jest darmowa (1) czy płatna (0), co pozwala uwzględnić wpływ modelu biznesowego gry na jej odbiór.

Zastosowane przekształcenia pozwalają lepiej przygotować dane do dalszego modelowania oraz zwiększają jakość informacji przekazywanych do algorytmów uczenia maszynowego.

I) Weryfikacja utworzonych cech

Po utworzeniu nowych zmiennych (`total_ratings`, `rating_ratio`, `log_ratings`, `is_free`) przeprowadzono ich weryfikację oraz analizę statystyczną. Analiza korelacji wykazała, że nowe cechy nie są silnie skorelowane ze sobą, co oznacza, że wnoszą różnorodną informację do modelu i nie dublują tych samych zależności. Dodatkowo sprawdzono brakujące wartości w całym zbiorze danych – po procesie przygotowania danych nie występują braki w żadnej z kolumn.

II) Transformacje danych

W ramach przygotowania danych zastosowano standaryzację wybranych zmiennych numerycznych przy użyciu `StandardScaler`. Proces ten polegał na przekształceniu danych do rozkładu o średniej równej 0 i odchyleniu standardowym równym 1. Transformacja została zastosowana do zmiennych takich jak `price`, `average_playtime`, `median_playtime` oraz `log_ratings`. Dzięki temu wszystkie cechy znajdują się na porównywalnej skali.

III) Uzasadnienie decyzji

W procesie `feature engineering` zdecydowano się na utworzenie nowych zmiennych oraz transformację istniejących danych w celu poprawy jakości informacji przekazywanych do modeli uczenia maszynowego. Zmienna `rating_ratio` została utworzona, ponieważ lepiej opisuje rzeczywistą ocenę gry niż same liczby pozytywne i negatywne recenzje, które mogą być zależne od popularności tytułu. Zmienna `total_ratings` pozwala natomiast określić ogólną popularność gry, niezależnie od jej jakości. Dodatkowo zastosowano transformację logarytmiczną (`log_ratings`) w celu zmniejszenia wpływu wartości odstających oraz standaryzację zmiennych liczbowych, co zapewnia ich porównywalność i poprawia stabilność modeli. Zmienne binarne, takie jak `is_free`, zostały wprowadzone w celu uwzględnienia różnicy pomiędzy grami darmowymi i płatnymi, co może mieć istotny wpływ na ich odbiór przez użytkowników.

IV) Wpływ feature engineering na model (porównanie przed i po)

W celu oceny wpływu `feature engineering` na skuteczność modelu przeprowadzono porównanie wyników klasyfikacji przed oraz po zastosowaniu nowych cech. Model trenowany na oryginalnych danych osiągnął dokładność na poziomie 0.696, co wskazuje na umiarkowaną skuteczność predykcji i ograniczoną ilość informacji zawartych w pierwotnych cechach. Po zastosowaniu `feature engineering`, obejmującego m.in. utworzenie zmiennych `rating_ratio`, `log_ratings` oraz `is_free`, dokładność modelu wzrosła do 0.993, co oznacza bardzo wysoką skuteczność klasyfikacji. Tak znaczący wzrost dokładności wskazuje, że nowe cechy w istotny sposób zwiększyły ilość informacji dostępnych dla modelu oraz poprawiły separowalność klas. Jednocześnie należy zauważyć, że tak wysoka skuteczność modelu może częściowo wynikać z tzw. `data leakage`, czyli sytuacji, w której niektóre cechy są silnie powiązane z definiowaną zmienną docelową lub wprost z niej wynikają (np. cechy oparte na tych samych informacjach co `target`). W takim przypadku model może osiągać zawyżoną skuteczność, ponieważ „uczy

się” zależności zbyt bliskich konstrukcji zmiennej docelowej. Pomimo tego zastosowane feature engineering znacząco poprawiło jakość modelu i pozwoliło lepiej wykorzystać informacje zawarte w danych.

11. Model i eksperymenty

W ramach etapu modelowania przeprowadzono eksperymenty z wykorzystaniem kilku modeli uczenia maszynowego w celu oceny ich skuteczności w zadaniu klasyfikacji.

Na początku zastosowano model bazowy DummyClassifier, który przewiduje najczęściej występującą klasę. Model ten uzyskał dokładność na poziomie 0.497, co stanowi punkt odniesienia dla pozostałych modeli i odpowiada działaniu zbliżonemu do losowego zgadywania.

Następnie wykorzystano model Logistic Regression, który osiągnął dokładność 0.993. Wynik ten wskazuje na silne zależności liniowe w danych oraz wysoką separowalność klas.

Kolejnym krokiem było zastosowanie modelu Random Forest Classifier, który uzyskał najlepszy wynik na poziomie 0.999. Model ten dzięki wykorzystaniu wielu drzew decyzyjnych dobrze radzi sobie z nieliniowymi zależnościami w danych.

W celu optymalizacji modelu przeprowadzono strojenie hiperparametrów przy użyciu GridSearchCV. Najlepszy model uzyskany w tym procesie osiągnął dokładność 0.997, co potwierdza wysoką jakość modeli zespołowych w tym zadaniu.

Dobór metryk

W celu oceny jakości modeli zastosowano metrykę accuracy, która określa ogólny odsetek poprawnie sklasyfikowanych przypadków. Dodatkowo analizowano wyniki modeli bazowych oraz zaawansowanych, co pozwoliło na porównanie ich skuteczności w zadaniu klasyfikacji.

Analiza wyników

Przeprowadzone eksperymenty wykazały znaczące różnice pomiędzy modelami. Model bazowy DummyClassifier osiągnął wynik na poziomie około 0.497, co stanowi punkt odniesienia.


Modele uczenia maszynowego osiągnęły znacznie lepsze wyniki:

- Logistic Regression: 0.993
- Random Forest: 0.999
- Random Forest po GridSearch: 0.997

Wyniki te wskazują na bardzo wysoką skuteczność modeli oraz dobrą separowalność danych.

Heatmapa

Wykres (zdjęcie poniżej) przedstawia macierz korelacji między cechami zbioru danych i pozwala ocenić siłę oraz kierunek zależności pomiędzy zmiennymi. Na jego podstawie można zauważyć, które cechy niosą podobną informację, a które są od siebie niezależne, co jest przydatne przy wyborze zmiennych do modelu. Takie zestawienie pomaga również wykryć ewentualną redundancję cech oraz lepiej zrozumieć strukturę danych przed etapem budowy modelu.



Zdj. 4 - Heatmapa

12. Wnioski z eksperymentów

Przeprowadzone eksperymenty wykazały, że modele uczenia maszynowego znacząco przewyższają model bazowy. Najlepsze wyniki osiągnął Random Forest, jednak wszystkie modele wykazały bardzo wysoką skuteczność, co może wynikać z dobrze przygotowanych cech oraz silnej separowalności danych. Jednocześnie należy uwzględnić możliwość występowania częściowego data leakage, który mógł wpłynąć na zawyżenie wyników.

13. Podsumowanie

Interpretacja wyników

Uzyskane wyniki sugerują, że zbiór danych zawiera silne zależności pomiędzy cechami a zmienną docelową. Szczególnie istotne okazały się cechy utworzone w procesie feature engineering, takie jak `rating_ratio` oraz `log_ratings`, które znacząco zwiększyły jakość predykcji. Bardzo wysokie wyniki modeli mogą również wskazywać na częściowe zjawisko data leakage, czyli sytuację, w której część cech jest silnie powiązana z definicją klasy, co może prowadzić do zawyżenia wyników.

Refleksja (co działało / co nie)

W projekcie najlepiej sprawdziły się modele oparte na Random Forest oraz Logistic Regression, które osiągnęły bardzo wysoką skuteczność predykcji. Szczególnie istotny wpływ miało zastosowanie feature engineering, które znacząco poprawiło jakość modeli. Z drugiej strony, bardzo wysokie wyniki mogą świadczyć o tym, że problem klasyfikacyjny był relatywnie łatwy lub że część cech była zbyt silnie skorelowana z targetem. W przyszłości warto byłoby zastosować bardziej rygorystyczną definicję zmiennej docelowej oraz dodatkowe metryki, takie jak precision i recall, aby dokładniej ocenić jakość modeli.

Osiągnięcie celu

Celem projektu była predykcja sukcesu gier komputerowych dostępnych na platformie Steam przy użyciu uczenia maszynowego. Model klasyfikacyjny został zaprojektowany w taki sposób, aby przewidywać, czy dana gra może zostać uznana za „sukces” na podstawie jej cech. Sukces gry został zdefiniowany na podstawie danych o liczbie pozytywnych ocen użytkowników. Gry zostały podzielone na dwie klasy: sukces (1) oraz brak sukcesu (0), w zależności od tego, czy liczba pozytywnych ocen przekraczała medianę w zbiorze danych. Model uczenia maszynowego analizuje takie cechy jak cena gry, liczba ocen, średni oraz mediana czasu gry, a także utworzone cechy (np. `rating_ratio`, `log_ratings`, `is_free`) i na ich podstawie przewiduje, do której klasy należy dana gra. W praktyce oznacza to, że model uczy się wzorców w danych i na ich podstawie potrafi określić, czy nowa, nieznana gra ma cechy typowe dla gier odnoszących sukces (wysokie oceny i popularność), czy też nie.